

# ANÁLISIS DE LA DESERCIÓN ESCOLAR EN BOLIVIA

## Hallazgos, Modelos Predictivos y Recomendaciones de Política Pública

**Fuente de datos:** Encuesta de Hogares (EH) 2025 — INE Bolivia

**Población analizada:** 9,895 niños, niñas y adolescentes de 6 a 18 años

**Metodología:** Análisis estadístico descriptivo + Machine Learning supervisado  
(Random Forest y Regresión Logística) + Clustering K-Means

### Modelos desarrollados:

**Modelo binario:** Predicción de asistencia escolar (AUC-ROC=0.907)

**Modelo multiclase:** Predicción del nivel educativo alcanzado (F1-Macro=0.854)

**Autor:** Marcos Ormachea Araya – Maestrante UPEA

## RESUMEN EJECUTIVO

La deserción escolar en Bolivia afecta al 3.42% de los niños y adolescentes de 6 a 18 años, lo que representa aproximadamente 339 estudiantes en la muestra analizada. Si bien la tasa es baja comparada con décadas anteriores —producto de programas como el Bono Juancito Pinto y el desayuno escolar—, todavía representa miles de estudiantes que abandonan el sistema educativo cada año, perpetuando el ciclo intergeneracional de pobreza.

Este proyecto aplica técnicas de ciencia de datos y Machine Learning para identificar los factores que más influyen en la deserción escolar, construyendo dos modelos predictivos complementarios:

1. Modelo binario (Asistencia\_Escolar): Responde "¿este niño está en riesgo de desertar?" — AUC-ROC = 0.907.
2. Modelo multiclase (Nivel\_Educativo\_Alcanzado): Responde "¿qué tan rezagado está este niño en su trayectoria educativa?" — F1-Macro = 0.854.

Los hallazgos principales revelan que la edad es el factor más determinante de la deserción (30.62% de importancia en el modelo binario), seguido por el rezago educativo (22.44%), el ingreso per cápita del hogar (10.03%) y el ratio de dependencia (8.42%).

Con base en estos resultados, se proponen 6 recomendaciones de política pública focalizadas en adolescentes, hogares vulnerables y zonas rurales.

## CONTEXTO Y METODOLOGIA

### Contexto del problema

La deserción escolar es uno de los principales desafíos educativos de Bolivia. Aunque el país ha logrado avances significativos en cobertura educativa en las últimas dos décadas, persisten brechas importantes:

| Indicador                              | Valor                                   | Fuente                                                         |
|----------------------------------------|-----------------------------------------|----------------------------------------------------------------|
| Tasa de deserción (6-18 años)          | 3.42%                                   | EH2025 (este estudio)                                          |
| Tasa de asistencia escolar (2021-2025) | ~94.3%                                  | INE Bolivia (referencia externa, no calculada en este estudio) |
| Brecha urbano-rural                    | 2-3 puntos porcentuales                 | INE Bolivia (referencia externa)                               |
| Principales causas declaradas          | Económicas, trabajo infantil, distancia | INE Bolivia                                                    |

### Fuente de datos

Encuesta de Hogares (EH) 2025 — Instituto Nacional de Estadística (INE) Bolivia.

- Acceso: Archivo Nacional de Datos (ANDA), previa solicitud.
- Formato original: SPSS (.sav).
- Tablas utilizadas: EH2025\_Persona (nivel individuo) y EH2025\_Vivienda\_1 (nivel hogar).
- Unidad de análisis: Individuo (6-18 años).
- Tamaño final del dataset: 9,895 individuos × 293 variables.

### Metodología

El proyecto se desarrolló en 4 etapas:

| Etapas                | Actividades                                                                             |
|-----------------------|-----------------------------------------------------------------------------------------|
| Preprocesamiento      | Carga de datos, EDA, limpieza, ingeniería de features (ICV, IASB, ratio de dependencia) |
| Análisis Exploratorio | Mapa interactivo, gráficos de barras, tendencias, clustering K-Means                    |
| Modelado ML           | Regresión Logística + Random Forest (binario y multiclase)                              |
| Storytelling          | Recomendaciones de política pública basadas en evidencia                                |

## HALLAZGOS PRINCIPALES

### Hallazgos principales


La deserción escolar en Bolivia afecta al 3.42% de los niños y adolescentes de 6 a 18 años. Los cuatro hallazgos principales son:

#### Hallazgo 1: La deserción se concentra en la adolescencia

La tasa de deserción pasa de menos del 1% a los 6 años a más del 15% a los 18 años. El punto de inflexión se ubica alrededor de los 15 años, coincidiendo con:

- El fin de la educación secundaria obligatoria.
- La presión por incorporarse al mercado laboral.
- La falta de oferta de secundaria completa en zonas rurales.

La Ilustración 1 muestra la tasa de deserción por edad (6-18 años). Se observa un patrón en forma de "J": estable en primaria, con aceleración a partir de los 15 años.



*Ilustración 1 - Tasa de deserción por edad*

#### Hallazgo 2: Brecha urbano-rural persistente

La deserción en el área rural es significativamente superior a la urbana:

| Métrica            | Valor                    |
|--------------------|--------------------------|
| Tasa urbana        | 2.43%                    |
| Tasa rural         | 6.42%                    |
| Brecha             | 3.99 puntos porcentuales |
| Ratio rural/urbano | 2.64x                    |

Este hecho, refleja desigualdades estructurales en:

- Infraestructura educativa (falta de colegios de secundaria completa).
- Condiciones socioeconómicas (pobreza, trabajo infantil agrícola).

- Acceso a servicios básicos (internet, electricidad).

### Hallazgo 3: Gradiente socioeconómico claro

Existe una relación inversa entre el ingreso per cápita del hogar y la deserción escolar. El 20% más pobre de los hogares presenta una tasa de deserción de 4.34%, mientras que el 20% más rico registra 3.63%. La brecha es de 0.72 puntos porcentuales (el 20% más pobre tiene una tasa 20% superior). Si bien la diferencia es modesta al comparar los extremos, el ingreso per cápita es la tercera variable más importante del modelo (10.03%), lo que sugiere que su efecto sobre la deserción es no lineal y se manifiesta con mayor fuerza en los deciles intermedios.

### Hallazgo 4: Heterogeneidad departamental

Los departamentos de Santa Cruz y Pando concentran las mayores tasas de deserción, mientras que los otros muestran mejores indicadores.

| Departamentos      | Nivel de deserción                                                                        |
|--------------------|-------------------------------------------------------------------------------------------|
| Santa Cruz         |  Alto  |
| Pando              |  Alto  |
| Beni               |  Medio |
| Chuquisaca, Tarija |  Medio |
| Potosí             |  Medio |
| La Paz, Oruro      |  Bajo  |
| Cochabamba         |  Bajo  |

## MODELO BINARIO – ASISTENCIA ESCOLAR

### Modelo binario: Predicción de Asistencia Escolar

#### Definición del problema

- **Variable objetivo:** Asistencia\_Escolar (1 = asiste, 0 = no asiste).
- **Tipo de problema:** Clasificación binaria supervisada.
- **Tamaño de la muestra:** 9,895 individuos (80% training / 20% test, estratificado).
- **Manejo del desbalanceo:** class\_weight = 'balanced' para compensar la baja proporción de desertores (3.4%).

#### Modelos entrenados

| Modelo              | Descripción                                         |
|---------------------|-----------------------------------------------------|
| Regresión Logística | Baseline interpretable. Coeficientes como log-odds. |

| Modelo        | Descripción                                                                    |
|---------------|--------------------------------------------------------------------------------|
| Random Forest | Modelo principal. 300 árboles, profundidad máxima 15. Captura no-linealidades. |


### Resultados del modelo binario

| Métrica   | Regresión Logística | Random Forest |
|-----------|---------------------|---------------|
| Accuracy  | 0.776               | 0.937         |
| Precision | 0.990               | 0.984         |
| Recall    | 0.776               | 0.950         |
| F1-Score  | 0.870               | 0.967         |
| AUC-ROC   | 0.864               | 0.907         |

#### Interpretación:

- El Random Forest supera a la Regresión Logística en 4 de 5 métricas.
- El AUC-ROC de 0.907 indica una capacidad discriminativa excelente.
- El Recall de 0.950 significa que el modelo detecta al 95% de los desertores reales.

La Ilustración 2 muestra que el Random Forest se mantiene consistentemente por encima de la línea diagonal, confirmando su buen desempeño.



*Ilustración 2 Curva ROC comparativa*

### Matriz de confusión (Random Forest)

|                 | Pred: No asiste | Pred: Asiste |
|-----------------|-----------------|--------------|
| Real: No asiste | 39 (VP)         | 29 (FN)      |
| Real: Asiste    | 95 (FP)         | 1,816 (VN)   |

Análisis:

- **39 Verdaderos Positivos:** Desertores correctamente identificados.
- **29 Falsos Negativos:** Desertores no detectados (riesgo de exclusión).
- **95 Falsos Positivos:** Asistentes marcados como desertores (costo de intervención innecesaria).
- **1,816 Verdaderos Negativos:** Asistentes marcados como asistentes.

## Top 10 variables más importantes

| Ranking | Variable                  | Importancia | Categoría  |
|---------|---------------------------|-------------|------------|
| 1       | Edad                      | 30.62%      | Individual |
| 2       | Años de estudio           | 22.44%      | Individual |
| 3       | Ingreso per cápita        | 10.03%      | Hogar      |
| 4       | Ratio de dependencia      | 8.42%       | Hogar      |
| 5       | Nivel educativo del jefe  | 7.00%       | Hogar      |
| 6       | Acceso a servicios (IASB) | 5.76%       | Vivienda   |
| 7       | Zona rural                | 3.36%       | Geográfica |
| 8       | Calidad de vivienda (ICV) | 3.24%       | Vivienda   |
| 9       | Santa Cruz (depto)        | 2.02%       | Geográfica |
| 10      | Sexo (mujer)              | 1.66%       | Individual |

### Lectura:

- **Factores individuales** dominan (53.06% de la importancia): edad y rezago educativo.
- **Factores del hogar** son secundarios pero relevantes (25.45%): ingreso y carga económica.
- **Factores de vivienda y geográficos** aportan 16.04%, y otros factores no incluidos en el Top 10 aportan el 5.45% restante.

## MODELO MULTICLASE – NIVEL EDUCATIVO ALCANZADO

### Modelo multiclase: Predicción del Nivel Educativo Alcanzado

#### Justificación

Además de predecir la asistencia, es importante **diagnosticar el rezago educativo** de los estudiantes. Un niño de 12 años que solo tiene primaria completa está en riesgo de desertar; uno con secundaria en curso está en trayectoria esperada.

**Variable objetivo:** Nivel\_Educativo\_Alcanzado con 3 clases:

- **0 = Ninguno** (nunca asistió o solo preescolar) → 8.65%
- **1 = Primaria** (algún grado de primaria) → 49.00%
- **2 = Secundaria** (algún grado de secundaria) → 42.22%

*(La clase "Superior" se excluyó por tener solo 12 casos en la población 6-18 años).*

#### Corrección de data leakage

En la primera iteración se detectó un **data leakage**: la variable aestudio (años de

estudio) es una transformación directa del target Nivel\_Educativo\_Alcanzado, lo que producía un nivel de **accuracy** artificialmente perfecto (100%). Se excluyó esta variable para obtener un modelo con valor predictivo real.

### Resultados del modelo multiclase (sin data leakage)

| Métrica     | Regresión Logística | Random Forest |
|-------------|---------------------|---------------|
| Accuracy    | 0.876               | 0.888         |
| F1-Macro    | 0.841               | 0.854         |
| F1-Weighted | 0.88                | 0.891         |

### Análisis de las matrices de confusión (Random Forest)

| Real \ Pred      | Ninguno                                 | Primaria                                | Secundaria                              |
|------------------|-----------------------------------------|-----------------------------------------|-----------------------------------------|
| Ninguno (171)    | 161 <input checked="" type="checkbox"/> | 5                                       | 5                                       |
| Primaria (970)   | 98                                      | 789 <input checked="" type="checkbox"/> | 83                                      |
| Secundaria (838) | 0                                       | 30                                      | 808 <input checked="" type="checkbox"/> |

#### Interpretación:

- **Clase "Ninguno"** se identifica con **94% de recall** (161/171): el modelo reconoce a los estudiantes con mayor rezago.
- **Clase "Secundaria"** se identifica con **96% de recall** (808/838): trayectoria esperada.
- **Clase "Primaria"** es la más difícil (frontera difusa con las otras dos clases).

### Top variables del modelo multiclase

| Ranking | Variable                        | Importancia |
|---------|---------------------------------|-------------|
| 1       | Edad                            | 83%         |
| 2       | Ratio de dependencia            | 11%         |
| 3       | Ingreso per cápita              | 3%          |
| 4       | IASB, nivel_ed_jefe, ICV, otros | <1% c/u     |

#### Lectura:

El modelo aprende que **la edad es el predictor más fuerte del nivel educativo** (a mayor

edad, más años acumulados de formación). El segundo factor es la **carga económica del hogar**, que puede acelerar o retrasar el avance educativo.

## COMPLEMENTARIEDAD DE LOS MODELOS

| Aspecto           | Modelo binario               | Modelo multiclase          |
|-------------------|------------------------------|----------------------------|
| Predice           | Asiste / No asiste           | Nivel alcanzado            |
| Uso               | Alerta temprana de deserción | Diagnóstico de rezago      |
| Métrica principal | AUC-ROC = 0.907              | F1-Macro = 0.854           |
| Top variable      | Edad (30.6%)                 | Edad (83%)                 |
| Aplicación        | Focalización de intervención | Priorización de nivelación |

En conjunto, los dos modelos permiten:

1. **Identificar** a los estudiantes en riesgo de desertar (modelo binario).
2. **Diagnosticar** su nivel de rezago (modelo multiclase).
3. **Focalizar** intervenciones según el perfil de cada estudiante.

## PATRONES GEOGRÁFICOS Y SOCIOECONÓMICOS

### Patrones geográficos y socioeconómicos

El análisis identificó **cinco patrones claros** que permiten focalizar políticas públicas:

#### Patrón 1: Focalización territorial

Los datos de la EH2025 revelan un patrón territorial distinto al esperado. A diferencia de la hipótesis inicial —que asociaba la mayor deserción con los departamentos del altiplano—, el análisis muestra que Santa Cruz (4.88%) y Pando (4.66%) concentran las tasas más altas, seguidas por Chuquisaca (4.00%) y Beni (3.92%). Por el contrario, Cochabamba (2.01%), La Paz (2.53%) y Oruro (2.82%) presentan los mejores indicadores, con tasas inferiores al promedio nacional de 3.42%. Este hallazgo sugiere que la deserción escolar no responde a un patrón geográfico simple, sino a una combinación de factores socioeconómicos, de composición urbano-rural y de dinámicas locales que merecen un análisis más profundo.




Ilustración 3 Mapa Interactivo (Disponible en repositorio)

| Ranking | Departamento    | No asiste  | Total        | Tasa de deserción | Nivel |
|---------|-----------------|------------|--------------|-------------------|-------|
| 1       | Santa Cruz      | 94         | 1,926        | 4.88%             | Alto  |
| 2       | Pando           | 30         | 644          | 4.66%             | Alto  |
| 3       | Chuquisaca      | 28         | 700          | 4.00%             | Medio |
| 4       | Beni            | 28         | 714          | 3.92%             | Medio |
| 5       | Tarija          | 24         | 674          | 3.56%             | Medio |
| 6       | Potosí          | 26         | 736          | 3.53%             | Medio |
| 7       | Oruro           | 20         | 708          | 2.82%             | Bajo  |
| 8       | La Paz          | 57         | 2,250        | 2.53%             | Bajo  |
| 9       | Cochabamba      | 31         | 1,543        | 2.01%             | Bajo  |
|         | <b>Nacional</b> | <b>338</b> | <b>9,895</b> | <b>3.42%</b>      | —     |

### Patrón 2 : Ciclo de vida educativo

La deserción es **casi nula en primaria (6-11 años)** y se **acelera en secundaria**, especialmente después de los 15 años. Este patrón refleja:

- La presión por incorporarse al mercado laboral.
- La falta de oferta de secundaria completa en zonas rurales.
- El costo de oportunidad creciente con la edad.

### Patrón 3: Capital cultural familiar

El nivel educativo del jefe de hogar es una de las variables más importantes del modelo (7.00%). Esto respalda la teoría de la transmisión intergeneracional de la educación: hijos de padres con mayor educación tienden a permanecer más tiempo en el sistema.


#### Patrón 4: Carga económica del hogar

El ratio de dependencia (8.42%) y el ingreso per cápita (10.03%) son factores determinantes. Los hogares con mayor carga económica tienen mayor riesgo de deserción, porque los adolescentes deben contribuir al ingreso familiar.

#### Patrón 5: Perfiles de vulnerabilidad (Clustering)

El análisis **K-Means** identificó **4 perfiles diferenciados** de riesgo educativo:

| Cluster  | Perfil                                  | Riesgo                                         |
|----------|-----------------------------------------|------------------------------------------------|
| <b>0</b> | Hogares con condiciones favorables      | <span style="color: green;">●</span> Bajo      |
| <b>1</b> | Hogares urbanos de clase media          | <span style="color: blue;">●</span> Bajo-Medio |
| <b>2</b> | Hogares rurales con servicios limitados | <span style="color: yellow;">●</span> Medio    |
| <b>3</b> | Hogares con múltiples desventajas       | <span style="color: red;">●</span> Alto        |



*Ilustración 4 Clustering K-Means (k=4)*

## RECOMENDACIONES DE POLÍTICA PÚBLICA

### Recomendación 1:

**Focalizar transferencias condicionadas en el decil más pobre**

**Acción:** Ampliar la cobertura y el monto del **Bono Juancito Pinto** para hogares en el **primer y segundo decil de ingreso**, con condicionalidad estricta de asistencia escolar verificada.

**Justificación:**

- El ingreso per cápita es la tercera variable más importante del modelo binario (10.03%).
- La deserción en el 20% más pobre es superior al 20% más rico.

**Indicador de éxito:** Reducir la tasa de deserción en el decil 1 en al menos 2 puntos porcentuales en 3 años.

**Recomendación 2:****Programa especial para adolescentes (15-18 años)**

**Acción:** Diseñar un programa que combine:

- Becas de transporte y alimentación.
- Formación técnica dual (educación + trabajo).
- Tutorías académicas para estudiantes en riesgo.

**Justificación:**

- La **edad** es la variable más importante del modelo binario (30.62%) y del multiclase (83%).
- La deserción se acelera a partir de los 15 años.

**Indicador de éxito:** Aumentar la tasa de asistencia en 16-18 años en al menos 3 puntos porcentuales.

**Recomendación 3:****Infraestructura educativa rural focalizada**

**Acción:** Construir y equipar **colegios de secundaria completa** en comunidades rurales de los departamentos con mayor deserción y mayor ruralidad (Santa Cruz, Pando, Chuquisaca y Beni).

**Justificación:**

- La zona rural tiene una importancia del 3.36% en el modelo.
- La falta de oferta de secundaria obliga a los adolescentes a migrar o abandonar.

**Indicador de éxito:** Reducir la brecha urbano-rural de deserción en al menos 2 puntos porcentuales.

**Recomendación 4:****Programa de alfabetización digital y conectividad**

**Acción:** Ampliar el acceso a **internet y dispositivos digitales** en hogares con niños en edad escolar.

**Justificación:**

- El IASB (que incluye internet) es la sexta variable más importante (5.76%).

- La pandemia evidenció la importancia de la conectividad.

**Indicador de éxito:** Alcanzar 80% de cobertura de internet en hogares con menores en edad escolar.

### **Recomendación 5: Sistema de alerta temprana basado en Machine Learning**

**Acción:** Implementar un sistema que use el modelo Random Forest entrenado para identificar hogares con alto riesgo de deserción.

**Justificación:**

- El modelo binario alcanzó un **AUC-ROC de 0.907** y un **Recall de 0.950**.
- Las variables más importantes son fácilmente medibles desde el sistema educativo.

**Indicador de éxito:** Identificar al menos el 80% de los desertores potenciales antes de que abandonen el sistema.

### **Recomendación 6: Programa de nivelación académica para estudiantes con rezago**

**Acción:** Identificar a los estudiantes con **rezago educativo** (nivel inferior al esperado para su edad) y ofrecerles programas de nivelación.

**Justificación:**

- El modelo multiclase identificó que la combinación **edad + ratio de dependencia** es el predictor más fuerte de rezago.
- El modelo alcanzó un **F1-Macro de 0.854**, permitiendo identificar estudiantes en riesgo.

**Indicador de éxito:** Reducir en 30% el porcentaje de estudiantes con rezago severo en 3 años.

## **CONCLUSIONES**

Este proyecto demuestra el valor del análisis de datos y el Machine Learning para informar políticas públicas basadas en evidencia.

Los 3 hallazgos más importantes

- La edad es el factor más determinante de la deserción escolar (30.62% en el modelo binario, 83% en el multiclase). Las intervenciones deben focalizarse en adolescentes de 15-18 años.
- El rezago educativo y el ingreso del hogar son los siguientes factores más relevantes. Programas de nivelación académica y transferencias condicionadas son clave.
- Las condiciones del hogar (vivienda, servicios, capital cultural familiar) explican una parte significativa del riesgo. Las políticas habitacionales y de conectividad también

contribuyen a la retención escolar.

#### **LIMITACIONES IDENTIFICADAS**

- **Anonimización geográfica:** La EH2025 limita la ubicación a nivel departamento, imposibilitando el análisis municipal.
- **Desbalanceo de clases:** La baja proporción de desertores (3.4%) afecta la precisión en la clase minoritaria.
- **Corte transversal:** La EH2025 no permite analizar trayectorias educativas a lo largo del tiempo.
- **Variables no observadas:** Factores como calidad docente o motivación personal no están en la encuesta.